

Doc-to-LoRA: Learning to Instantly Internalize Contexts

Rujikorn Charakorn¹ Edoardo Cetin¹ Shinnosuke Uesaka^{*2} Robert T. Lange¹



sakana.ai



Rujikorn Charakorn

Sakana AI
Verified email at sakana.ai - [Homepage](#)

Sakana AI研究员，致力于研究使模型适应更易于指定和重用的方法。
作者主页: [Tan](#)

ICML'26

汇报人：刘佳伟 2026年9月14日

1

背景与现状

2

机遇与挑战

3

方法设计

4

实验与总结

1

背景与现状

2

机遇与挑战


3

方法设计


4

实验与总结

长文本问答现状




- 上下文窗口有限，出现了截断？
- “迷失在中间”（Lost-in-the-Middle）现象？
- ...



- RAG ? 依旧无法脱离上下文窗口限制!
- 依靠缓存提高复用率? 资源开销依旧大, 且没法脱离上下文窗口限制!

每次回答都要重新把文档放入上下文窗口: 注意力计算和 KV cache 都随上下文增长

把记忆存到LLM参数里



- 1.教师模式 (**Teacher**)：让模型在包含丰富上下文的条件下，生成最终答案。
- 2.学生模式 (**Student**)：微调同一个模型，要求它在没有这些上下文信息的情况下，直接预测上述生成的最终答案。

这种更新过程通常较慢且计算量大

1

背景与现状

2

机遇与挑战


3

方法设计

4

实验与总结

LoRA作为记忆



机遇:

- ✓ 记忆不受上下文窗口限制: 参数化记忆
- ✓ 节省记忆更新带来的计算开销: 远小于更新LLM

挑战:

- ✓ 文档特异性: 不同文档通常需要重新训练
- ✓ 容量上限: LoRA 作为参数化记忆存在容量上限

1

背景与现状

2


机遇与挑战

3


方法设计

4


实验与总结



- 传统：成为某个文档的专属外挂参数记忆
- D2L：学习如何将文档变成适配LLM Activation的过程




训练阶段的输入: D->Answer, Q




- 既不破坏LLM原有能力，又让其拥有了快速准确回答新问题的能力
- LoRA学习到的是文档的参数化记忆：例如学出LoRA为 $f(x) = x^2$

挑战：文档特异性+能力上限

元学习上下文蒸馏 (D2L)



训练阶段的输入: D->Activations, Q



- 超网学习到的是，如何把文档变成LLM看过文档后的Activations:

- 例如 $H(x) = f(x) = ?$

- 新文档来时， $H(x)$ 则会产生LLM看到该文档的Activations:

- 例如 $H(x) = f(x) = 2x$


文档特异性? 多类文档参与训练!

容量上限?

通过分块进行长上下文组合



长文档 (超出上下文窗口)



1

背景与现状

2

机遇与挑战

3

方法设计

4

实验与总结

实验设置



➤ 元训练集

数据来源	用途
FineWeb-Edu 子集	通用英文文档主来源, 约 9 亿原始 token
PwC	passage-grounded QA 补充
SQuAD	阅读理解格式补充
DROP	数值与离散推理 QA 格式补充
ROPES	背景知识与关系推理 QA 格式补充

➤ Benchmark

名称	任务类型	主要考察能力
NIAH	[自制]“大海捞针”任务	长文档信息内化
SQuAD	抽取式阅读理解	从短文档中提取事实
DROP	离散推理、数值推理	需要计算或组合 passage 信息
ROPES	背景知识推理	将背景知识与文档信息结合
2WikiMultihopQA	多跳问答	跨文档或跨段落组合证据
MultiFieldQA	多领域长文档问答	长文档信息内化
QASPER	科学论文问答	科学长文档理解

➤ 数据规模

- 约 1.01 亿个 context-query-response triplets

➤ 基础模型

- gemma-2-2b-it

➤ 上下文窗口大小

- 8K tokens

➤ LoRA作用点

- MLP 投射层

➤ 训练参数量

- 309M

➤ 每轮辅助问题数

- 10

➤ 训练策略

- 阶段 1: 80K steps, 只生成单块 LoRA
- 阶段 2: 20K steps, 随机拆为 1 至 8 块, 学习可组合 LoRA
- [作者指出: 一开始就训练多块 LoRA 会不稳定]



➤ 对比基线

- **CD (oracle):** 直接在测试集上训练模型，仅作为LoRA方法上界
- **CD with generated queries:** 为每个新文档，专门以NTP 损失方式训练模型
- **T2L:** LoRA方法，但作用于KV投射层
- **Base model without context:** 基础模型不读取文档，也不加载任何文档专属 LoRA，仅作为ICL方法下界
- **Base model with context:** 基础模型读取文档，不加载任何文档专属 LoRA，仅作为ICL方法上界
- **Base model with truncated context:** 当文档超过模型上下文窗口时，只保留被截断后的文档输入模型
- **LLMLingua-2:** 先压缩原始文档，再将压缩后的文档和 query 输入基础 LLM

➤ 评价指标

- **QA performance :** 先计算其回答与 ground-truth 的 ROUGE-L F1，再相对于基础模型直接读取 context 的结果进行归一化 (↑)
- **Update latency :** 将一份新文档转化为可加载模型记忆所需的时间 (↓)
- **Peak update memory :** 生成或训练文档专属 LoRA 时的额外显存 (↓)
- **Generation memory:** 文档已经内化后，模型回答后续 query 时需要的额外显存 (↓)


D2L能力验证（“大海捞针”任务）



- **记忆能力：**成功实现知识内化，使基础模型能够在不阅读原始上下文的情况下回忆植入的信息
- **上下文窗口限制：**有效地绕过基础语言模型固有的上下文长度限制
- **性能：**减少推理的计算要求，特别是当输入很长时

D2L在真实 QA 上的表现

SQuAD



逐层算 (可以及时释放该层的中间计算结果) 和一次算所有层 (只调度一次大型前向计算)

Figure 3. QA performance on SQuAD compared to the used context length ratio (left), update latency (middle), and additional memory needed for model updates (right). LLMingua-2 compresses the input with [10%, 20%, 40%, 60%, 80%, 90%] compression rates from right to left (gray dots).

归一化表现最接近CD (Oracle), 且内化记忆时间短, 模型更新所需的额外显存也低

D2L在真实长文档的表现



Table 1. Performance, update memory, and latency of in-parameter knowledge methods on 2WikiMultihopQA benchmark.

Method	Normalized Performance ($\uparrow$)	Additional Update Memory (GB, $\downarrow$)	Mean Update Latency (s, $\downarrow$)
CD (oracle query)	0.901	7.820	40.171 ± 0.351
D2L (batched)	0.857	11.522	0.209 ± 0.123
D2L (iterative)	0.844	3.791	0.551 ± 0.101
CD (25 generated queries)	0.745	59.925	465.454 ± 67.868
CD (5 generated queries)	0.704	79.371	72.537 ± 7.821




Figure 4. Long document QA performance. LLMingua-2 compresses the input with [20%, 40%, 60%, 80%, 90%] compression rates from right to left (gray dots).


Table 2. Using a VLM as the context encoder.

	SQuAD	DROP	ROPES	Imagenette
D2L (LLM $\Rightarrow$ LLM)	0.814	0.655	0.906	N/A
D2L (VLM $\Rightarrow$ LLM)	0.705	0.568	0.772	75.03%

- **训练阶段：**同样的训练过程，只是使用的LM上下文编码器有所不同。Imagenette仅作为测试集
- **评估阶段：**看图像，然后问：“此图像中是什么？请准确选择以下类别之一：丁鳅、英国跳雀、录音机、电锯、教堂、圆号、垃圾车、加油泵、高尔夫球、降落伞。仅响应正确的类别，无需任何其他文本。”

- **D2L可跨模态传递信息**

极端内化情况



- 训练时：内化“查询”
- 评估时：只看文档

Table 3. SQuAD query internalization.

Method	Recall	Precision
Base model w/ context	0.886	0.876
D2L	0.740	0.720
D2L (swapped)	0.587	0.044
Base model w/o context	0.185	0.205

- Precision低：输出很长，答案只占一小部分，或者不包含答案
- Recall高：大部分输出都有答案

- 不同的内化操作，可以让D2L内化不同信息

Table 4. SQuAD (100 samples) performance with varying queries.

Method	Normalized Performance	Update Latency (s)
CD (oracle)	0.988	8.763 $\pm$ 0.313
D2L	0.866	0.086 $\pm$ 0.061
CD (100 generated queries)	0.650	631.101 $\pm$ 12.879
CD (50 generated queries)	0.601	311.661 $\pm$ 7.211
CD (20 generated queries)	0.506	129.044 $\pm$ 5.813

- 先验
 - 共识：训练时，每轮使用的辅助问题数越多，越能准确记住文档
 - D2L训练时，每轮辅助问题数=10

- **D2L远超CD (100)**

总结

- 大规模元训练，让一个超网络学会把文档的 LLM activation 直接映射成文档专属 LoRA。
 - 新文档到来时，只需一次前向传播生成 LoRA，后续查询不再输入原文。
 - 相比传统 CD，D2L 内化更快，更省计算资源，连续追问下，不仅回答地准，所需的额外显存更少。
- 此外，D2L 无需针对新文档重新训练模型。




Figure 1. An overview of D2L training (left) and downstream performance (right). D2L learns to efficiently internalize information, outperforming traditional CD while significantly reducing latency and memory consumption across question-answering benchmarks under limited query budgets.

➤ 1能否进一步提高？

- 1、长上下文切块并由多个超网生成独立LoRA，再拼接在一起。然而使用时，查询会使用所有LoRA，可能引入不相关知识，可以考虑做LoRA路由，让回答更准确。
- 2、训练中只有正样本，没有负样本，可能导致模型过度激活文档信息。这会导致，在问文档无关问题时，本来LLM能做对，但受到LoRA影响，却做不对了。可以增加负样本，让LoRA既保留记忆，又承担记忆门控角色。

➤ 2能否泛化？

现在实现了文档无关性。能否实现模型无关性？现在换个基础模型，要重新训练超网。如果训练时，就使用多种基础模型呢？那么就需要训练一个模型无关（文档无关性也要保留）的记忆编码器，同时为了适配不同类型的输出，还应添加一个把通用记忆翻译成目标模型 LoRA 的自适应解码器。（超网的训练时间要增加一些）

➤ 3能否用到我们的场景？

CaP要面临机器人能力的异构性（基础能力存在差异，API也存在差异）。把机器人能力、API 规范、示例程序和安全约束等内化到LoRA很有意义。那么只要基于D2L学会这种内化过程，在面对新机器人时，就可以轻易适配了，也就不再让VLM花费大量上下文窗口记住机器人特性。