



GREEN: Carbon-efficient Resource Scheduling for Machine Learning Clusters

NSDI 2025



Kaiqiang Xu, Decang Sun, Han Tian, Junxue Zhang, Kai Chen

王兆年


2026.09.07

汇报内容

- | | | |
|----|-------|------------------|
| 01 | 研究问题 | 训练能耗、电网碳强度与完成时间 |
| 02 | 系统设计 | 功耗计量、GPU 扩容与时间迁移 |
| 03 | 实验评估 | 主实验、消融实验 |
| 04 | 讨论与总结 | |

研究对象：多租户机器学习集群

多个用户共用固定 GPU 资源，训练任务需要排队



作业完成时间 JCT

完成时刻 - 提交时刻



作业碳排放的计算方法

$$\text{FOOTPRINT}_{\text{job}}(T) = \int_0^T P_{\text{job}}(t) \text{CIC}(t) dt$$

作业功率 $P_{\text{job}}(t)$

训练作业在每个时刻的用电功率

单位: kW

受 GPU 配置和作业运行状态影响

电网碳强度 $\text{CIC}(t)$

单位电能对应的二氧化碳排放

单位: kgCO_2/kWh

由电网供电结构决定, 并随时间变化

两条时间序列在同一时刻相乘, 并在作业运行期间累积。

GPU 扩容不一定降低总能耗


$$W_{\text{job}} = \int P_{\text{job}}(t) dt \approx \bar{P}_{\text{job}} T_{\text{run}}$$

资源配置

运行时长

功率 × 时间 = 能耗


1 张 GPU



10 h

$$0.3 \text{ kW} \times 10 \text{ h} \\ = \mathbf{3.0 \text{ kWh}}$$

2 张 GPU



8 h

$$0.6 \text{ kW} \times 8 \text{ h} \\ = \mathbf{4.8 \text{ kWh}}$$

运行时间减少 20%，仍不足以抵消功率翻倍，总能耗增加 60%。

GPU 配置需要依据单位能耗的训练进度，而不能只依据训练速度。

GREEN 的两个调度决策

在固定 GPU 容量下，系统需要同时控制作业能耗和计算负载的运行时间。

资源配置

决策	每个作业分配多少张 GPU
影响	作业功率与运行时间
依据	Energy Efficiency, Degradation


运行排序

决策	当前时段运行哪些作业
影响	功率需求与碳强度曲线的时间对应
依据	Footprint, Shifting, Priority

共同约束 固定集群容量，不修改训练超参数，并控制 JCT 与作业饥饿。

Carbon Tracker 提供统一测量，两个优化器分别生成资源配置和运行排序。


GREEN 系统架构



Carbon Tracker: 从功率曲线得到累计碳排放

Step 1 | 估计作业功率

$$P_{job}(t) = P_{gpu}(t) + P_{cpu_model}(t) + P_{static}$$



Step 2 | 累积碳足迹

$$\text{FOOTPRINT}_{\text{job}}(T) = \int_0^T P_{\text{job}}(t) \text{CIC}(t) dt$$

CIC

Carbon Intensity Curve: 每小时电网碳强度曲线

单位: 功率用 kW, CIC 用 kgCO₂/kWh, 积分结果为 kgCO₂。

能效优化器：用 Degradation 决定是否继续扩容

Energy Efficiency: 每单位能量推进多少训练

理论定义 Eq. (1)

$$\text{EFFICIENCY}_{\text{job}}(t) = \frac{d \text{Progress}_{\text{job}}(t)}{dW_{\text{job}}(t)}$$

运行时采样 Eq. (2)

$$\text{EFFICIENCY}_{\text{job}}(t) = \frac{\text{Progress}_{\text{job}}(t) - \text{Progress}_{\text{job}}(t - \Delta t)}{W_{\text{job}}(t) - W_{\text{job}}(t - \Delta t)}$$

Progress 不可得时 Eq. (3)

$$\text{EFFICIENCY}_{\text{job}}(t) = \frac{\sum_{t'=t-\Delta t}^t \text{Throughput}_{\text{job}}(t')}{W_{\text{job}}(t) - W_{\text{job}}(t - \Delta t)}$$

Degradation: 相对能效保留比例

$$\text{DEGRADATION}_{\text{job}}(t) = \frac{\text{EFFICIENCY}_{\text{job}}(t)}{\text{EFFICIENCY}_{\text{job}}(t_0)}$$

基准：作业使用最小 GPU 数时的初始配置

1.0	能效没有下降
0.9	能效下降 10%
0.7	能效下降 30%

比值越小，扩容越不划算

$$\text{DEGRADATION}_{\text{job}}(t) \geq \gamma \implies n_{\text{GPU}} \leftarrow n_{\text{GPU}} + 1$$

满足才继续加 1 张 GPU；否则停止。阈值 0.9 = 最多容忍 10% 能效下降。

碳足迹优化器：Shifting 如何选择运行时机

先把作业功率归一化（范围由迁移强度参数控制）：

$$P_{\text{job}}^* = \frac{P_{\text{job}} - P_{\min}}{P_{\max} - P_{\min}}(\mu - 1) + 1, \quad P_{\text{job}}^* \in [1, \mu]$$

迁移强度参数取 1 时，所有 Shifting Factor 都等于 1，相当于关闭时间迁移。

当前时段	低功率作业 $P_{\text{job}} \leq \tilde{P}$	高功率作业 $P_{\text{job}} > \tilde{P}$
低碳时段 $\text{CIC}(t) \leq \bar{I}$	$\text{SHIFTING}_{\text{job}} = P_{\text{job}}^*$ 分数变大 → 相对延后	$\text{SHIFTING}_{\text{job}} = \frac{1}{P_{\text{job}}^*}$ 分数变小 → 优先运行
高碳时段 $\text{CIC}(t) > \bar{I}$	$\text{SHIFTING}_{\text{job}} = \frac{1}{P_{\text{job}}^*}$ 分数变小 → 优先运行	$\text{SHIFTING}_{\text{job}} = P_{\text{job}}^*$ 分数变大 → 相对延后

两个边界分别是历史平均碳强度与作业 GPU 功率中位数。绿电时段优先高功率，高碳时段优先低功率。

最终排序：三个量如何合成 Priority

$$\text{PRIORITY}_{\text{job}} = \left(\frac{\text{FOOTPRINT}_{\text{job}}}{\text{DEGRADATION}_{\text{job}}} \right) \text{SHIFTING}_{\text{job}}$$

Footprint

累计运行碳排放

越大 → 分数越大 → 相对靠后
具有类似 LAS 的公平性作用：已获得服务越多，越可能让出资源。

Degradation

相对能效保留比例

越小 → 除法结果越大 → 相对靠后


Shifting

执行时机偏好

小于 1 → 分数变小 → 相对提前
大于 1 → 分数变大 → 相对延后。

Priority 数值越小，实际调度优先级越高。


MLFQ: 多级反馈队列



Upper Queue

Profiling and scale resource allocation

Goal: Optimize energy efficiency



Lower Queue

Shift high-power jobs to greener time

Goal: Optimize cluster carbon footprint

上层确定 GPU 配置，下层按碳感知优先级选择当前运行作业。

监测与调度采用不同时间尺度

触发方式	执行内容
每 30 秒	采样功耗与训练进度
每 30 分钟	主动重排作业，更新运行集合
作业完成时	沿用最近排序补位，不重算优先级或触发抢占


使用检查点与恢复机制完成任务切换

作业切换相关时间计入 JCT。主动调度不等于所有作业都强制重启。


实验设置与比较条件

实验要素	设置
硬件	32 个节点，每节点 2 张 RTX 3090，共 64 张 GPU
工作负载	791 个生产训练作业，按 24 小时原始提交序列回放
碳强度数据	2023 年 8 月，英国、加州、瑞典与波兰历史数据
主实验基线	Tiresias、GAIA Carbon-Time、EcoVisor
评价指标	集群碳足迹、平均 JCT、尾部 JCT

所有柱值均以各场景下的 GREEN = 1 归一化



调度轨迹体现高低功耗作业的时间迁移



UQ

上层队列作业

LQ-Low

下层低功耗作业

LQ-High

下层高功耗作业

高碳时段提高低功耗作业的运行比例，未将全部高功耗作业停止。

消融实验：资源扩容与时间迁移的贡献

调度方案	平均 JCT (h)	尾部 JCT (h)	碳足迹 (kgCO ₂)
完整 GREEN	17.56	45.20	15.88
固定 1 张 GPU	19.91	48.89	18.38
固定 2 张 GPU	18.53	46.57	16.71
碳因子改为 GPU 小时	18.30	47.15	18.52
关闭时间迁移	17.19	44.99	18.93

固定 GPU 配置或关闭时间迁移后，这组实验中的碳足迹均增加

总结与算冷电协同调度的研究联系

GREEN 已验证

资源配置 相对能效决定 GPU 数量，减少无效扩容带来的能耗。

运行排序 碳强度参与作业排序，以有限 JCT 代价降低运行碳排放。

研究讨论

GREEN 调整已有作业的运行时刻。若低碳、低负载时段任务不足，能否提前完成可复用计算？

可保留的对象	大模型中的载体	成立条件
训练进度	Checkpoint、阶段性模型更新	后续继续同一训练过程
推理中间状态	Prefix / KV Cache	请求能够复用相同前缀或上下文
计算结果	Semantic Cache、Embedding / Index、预生成 token	查询相似或未来需求可预测，结果仍有效



谢谢

欢迎提问与讨论

GREEN / NSDI 2025